



Universidad Internacional de La Rioja

Maestría en Análisis y Visualización de Datos Masivos

Seminario de Innovación en Análisis y Visualización de Datos

**Creación y Preparación de un Marco de Trabajo
para PYMES en Análisis de Datos**

Trabajo fin de estudio presentado por:	Andrea Jasmín Martínez López Josué Alexander Rivas Fabián José Miguel Meza Reyes Marco Antonio Calderón Yáñez Osvaldo Ramírez
Tipo de trabajo:	Entrega Final
Director/a:	Barbaro Jorge Ferrero Castro
Fecha:	29 de Septiembre del 2025

Índice de contenidos

1. Error! Bookmark not defined.

1.1. Error! Bookmark not defined.

1.1.1. 7

1.1.2. 7

1.2. Error! Bookmark not defined.

1.2.1. 7

1.2.2. 7

1.2.3. 7

1.3. Error! Bookmark not defined.

1.3.1. 7

1.3.2. 7

1.4. Error! Bookmark not defined.

1.4.1. 7

1.4.2. 7

1.4.3. 7

1.4.4. 7

1.4.5. 7

2. Error! Bookmark not defined.

2.1 EDA (EXPLORATION DATA ANALYSIS) 18

2.1.1. INTRODUCCIÓN AL EDA 19

2.1.2. RESUMEN ESTADÍSTICO DE LAS VARIABLES 20

2.1.3 ANÁLISIS DE VARIABLES 21

2.1.4 ANÁLISIS DE GRÁFICOS 23

2.2 MODELADO DE DATOS	25
2.2.1 MODELOS	25
2.2.2 TÉCNICAS UTILIZADAS	26
2.2.3 JUSTIFICACIÓN DE LA SELECCIÓN DE MODELOS	27
2.2.4. TÉCNICAS DE VALIDACIÓN DEL MODELO	27
2.2.5. DATOS EN ENTRENAMIENTO Y PRUEBA	28
2.2.6. EVALUACIÓN Y COMPARATIVA DEL RENDIMIENTO MODELO	29
2.2.7. INTERPRETACIÓN DE LOS RESULTADOS DEL MODELO	30
3. Error! Bookmark not defined.	
3.1 EVALUACIÓN Y DISCUSIÓN DE LOS RESULTADOS	31
3.1.1. PRESENTACIÓN VISUAL DE LOS RESULTADOS	31
3.1.2. INTERPRETACIÓN Y RELEVANCIA	34
3.1.3. COMPARACIÓN CON LOS OBJETIVOS DEL PROYECTO	34
3.1.4. HALLAZGOS CLAVE Y OPORTUNIDADES DE MEJORA	35
3.2 CONCLUSIONES	36
3.2.1. RESUMEN DE LOS RESULTADOS Y LOGROS	36
3.2.2. REFLEXIONES FINALES Y APRENDIZAJE	37
4. PROTOTIPO Y RECOMENDACIONES	38
4.1 PROTOTIPO	39
4.2 RECOMENDACIONES Y PRÓXIMOS PASOS	39
4.2.1. RECOMENDACIONES BASADAS EN RESULTADOS	40
4.2.2. PRIORIZACIÓN DE ACCIONES	40
4.2.3. PLAN DE IMPLEMENTACIÓN BASICO	40

4.2.4. SEGUIMIENTO Y EVALUACIÓN	40
4.2.5. PRÓXIMOS PASOS EN LA INVESTIGACIÓN	40
4.2.6. FORMACION Y CAPACITACION	41
5. ANEXOS	43
5.1 ENLACE PARA VISUALIZAR DASHBOARD ONLINE	43
5.2 CÓDIGO PARA CREACIÓN DE MODELO ENTIDAD RELACIÓN	43
5.3 CÓDIGO DE TÉCNICAS DE DIVISIÓN DE DATOS Y EVALUACIÓN	60
5.4 CÓDIGO DE EDA Y ANÁLISIS EXPLORATORIO	61
BIBLIOGRAFÍA	126

Índice de tablas

Tabla 1. Tabla que describe todos los CSV que usamos en el trabajo	10
Tabla 2. sales (606087 registros)	11
Tabla 3. customers (2294 registros).	11
Tabla 4. employees(350 registros).	12
Tabla 5. physicians (3782 registros).	12
Tabla 6. products (6693 registros).	12
Tabla 7. stores (44 registros).	13
Tabla 8. Detalle de cada métrica a medir	28
Tabla 9. Comparativas de modelos	29

Índice de Imágenes

Imagen 1.	21
Imagen 2.	22
Imagen 3.	22
Imagen 4.	23
Imagen 5.	23
Imagen 6..	24
Imagen 7.	24
Imagen 8.	31
Imagen 9.	32
Imagen 10.	32
Imagen 11.	33
Imagen 12.	33
Imagen 13 .	38
Imagen 14 .	39

1. Introducción

Hoy en día, las pequeñas y medianas empresas (PYMES) enfrentan importantes retos en la gestión y análisis de sus datos. Uno de los principales desafíos es la falta de herramientas accesibles y estructuradas que les permitan obtener información valiosa a partir de sus registros de ventas. En muchos casos, las decisiones se basan en intuiciones o en reportes poco detallados, lo que limita la capacidad de identificar tendencias, oportunidades de crecimiento y factores críticos para el éxito del negocio.

Ante esta necesidad, se plantea el desarrollo de un marco de trabajo que facilite a las pymes transformar sus datos crudos en información útil para la toma de decisiones estratégicas.

Recursos limitados

- Presupuestos para herramientas de análisis avanzadas
- Personal limitado con conocimiento especializado
- Infraestructura tecnológica
- Dificultad para integrar datos de múltiples fuentes.

Carencia Metodológica

- Falta de marcos de trabajo estandarizados adaptados a su escala
- Ausencia de mejores prácticas
- Limitado conocimiento en ciencia de datos

Falta de Competitividad

- Decisiones basadas en “feeling” en lugar de datos objetivos
- Pérdida de oportunidades de crecimiento
- Dificultad para competir con organizaciones más grandes

Mediante la implementación de un proceso automatizado de extracción, transformación y carga (ETL), es posible generar datasets específicos que puedan ser consultados y visualizados a través de plataformas de análisis como Power BI, permitiendo la construcción de dashboards interactivos que respondan a preguntas clave del negocio.

Este proyecto propone diseñar un marco de trabajo flexible y reutilizable que, a partir de un solo dataset de ventas en formato crudo, permita automatizar la generación de reportes y dashboards que proporcionen información sobre el comportamiento de las ventas, la fidelidad de los clientes, el rendimiento de los empleados y la identificación de productos estratégicos. La solución está pensada para ser adaptable a cualquier empresa del sector ventas que desee obtener estos análisis de forma rápida, eficiente y accesible desde la nube.

1.1.Descripción General

Diseñar un marco de trabajo práctico y accesible que proporcione una metodología sistemática, escalable y accesible, que permita a las PYMES transformar sus datos operativos en insights estratégicos, en objetivos claros y precisos independientemente de su sector o nivel tecnológico.

El Acceso al Análisis de Datos de ser generalizado para todo tipo de organización

1. Crear metodologías accesibles para empresas con recursos limitados
2. Reducir el “gap” tecnológico mediante herramientas de código abierto.
3. Proporcionar alternativas según capacidades organizacionales.
4. Desarrollar plantillas reutilizables para diferentes tipos de sectores.
5. Uso de mejores prácticas específicas para cada tipo de PYME.
6. Diseño de Implementaciones graduales, por fases.
7. Establecer mínimos y máximos de inversión inicial en infraestructura tecnológica
8. Preparación para el escalamiento del crecimiento del negocio.
9. Generar insights desde la implementación inicial
10. Establecer métricas de éxito y seguimiento de beneficios
11. Optimizar procesos operativos mediante análisis cuantitativo
12. Capacitar a los diferentes departamentos para la interpretación de información.
13. Fomentar la cultura de decisiones basada en ‘datos’
14. Crear autonomía en el mantenimiento y evolución del sistema

1.1.1. Crear autonomía en el mantenimiento y evolución del objetivo General

- **Accesibilidad Económica.** Como prioridad la búsqueda de herramientas gratuitas y de código abierto, que puedan ser escalables según el crecimiento del negocio.
- **Simplicidad Operativa.** Procesos simples y fáciles de implementar por personal con conocimientos técnicos básicos, evitando complejidades innecesarias.
- **Fácil adaptación.** Métodos y plantillas para diferentes rubros de negocios: ventas, servicios, manufactura, saludo, etc. etc.

- **Crecimiento Gradual.** Implementación por etapas, por tiempos, por departamentos que permitan crecer gradualmente sus capacidades analíticas.
- **Medio ambiente.** La importancia de tener códigos, plantillas, dashboards que puedan ser utilizados y adaptados en otras áreas, reduciendo tiempos.

1.1.2. Objetivos Específicos

- **Conociendo el negocio, evaluación del sector**
 1. Diagnóstico de los datos.
 2. Identificación de los orígenes de los datos.
 3. Búsqueda y Definición de objetivos claros y KPIs críticos
- **Tecnología.**
 1. Selección de stack tecnológico apropiado.
 2. Configuración de entorno de desarrollo.
 3. Establecimiento de procesos de seguridad y respaldo.
- **Extracción automatizada de datos desde diferentes orígenes.**
 1. Transformación mediante scripts Python.
 2. Carga en bases de datos/CSV optimizadas para análisis
- **Desarrollo de insights**
 1. Creación de dashboards interactivos e Informes automáticos
 2. Implementación de alertas y monitoreo de KPIs
 3. Capacitación del equipo en interpretación de resultados

1.2. Resumen ejecutivo

Este proyecto ofrece un marco de trabajo práctico y accesible para que las pequeñas y medianas empresas (PYMES) apliquen técnicas de ciencia de datos a sus ventas, transformando información cruda en insights estratégicos que impulsen la toma de decisiones comerciales.

Mediante un flujo de trabajo estructurado que abarca la definición del dataset, su extracción, transformación y carga (ETL), y la generación de visualizaciones interactivas, las PYMES podrán convertir datos dispersos en conocimiento accionable. La solución está diseñada para

gerentes de ventas y equipos operativos, con un enfoque en la accesibilidad, evitando la dependencia de software costoso o expertise técnico avanzado.

1.2.1. Justificación

Las PYMES enfrentan un problema crítico en el uso de datos: aunque generan información valiosa, carecen de las herramientas y conocimientos técnicos para transformarla en insights accionables. Este proyecto aborda ese desafío mediante una solución escalable, basada en tecnologías de código abierto, que elimina la dependencia de costosas licencias y complejas infraestructuras.

1.2.2. Beneficios

- Descubrimiento de tendencias estacionales, productos estrella y oportunidades de crecimiento.
- Capacidad para responder rápidamente a cambios en el mercado gracias a datos en tiempo real.
- Implementación de ciclos de mejora basados en métricas objetivas y resultados medibles.
- Desarrollo de campañas y tácticas de venta respaldadas por análisis cuantitativos.
- Maximización del retorno de inversión mediante decisiones precisas y reducción de costos operativos.

1.2.3. Estimación de posibles Requerimientos

- Equipo con capacidad de procesamiento medio-alto (mínimo 8GB RAM, procesador i5 o equivalente) para ejecución eficiente de procesos ETL y análisis.
- Suite de herramientas libres:
 - Python (Pandas, NumPy) para transformación de datos
 - SQL como motor de base de datos
 - Power BI (versión Free) para visualización
- Personal con nociones básicas en análisis de datos (se incluye capacitación en el marco de trabajo)
 - Equivalente a 1 FTE (Full-Time Equivalent) durante la implementación

- Tiempo de implementación estimado: 2 a 4 semanas.
 - Curva de aprendizaje: 1 semana adicional para capacitación

1.3. descripción de los datos

El conjunto de datos utilizado en este trabajo proviene de archivos CSV y consisten en las ventas de una cadena de tiendas del sector salud. Esta información fue proporcionada de manera estructurada en formato tabular, representando múltiples dimensiones de la operación: ventas (sales), productos (products), empleados (employees), clientes (customers), médicos (physicians) y sucursales (stores).

Algunos aspectos relevantes identificados en los datos son:

1. Todas las tablas están estructuradas en formato tabular, con columnas separadas y encabezados definidos.
2. Los campos que contienen fechas en las tablas sales y employees tienen un formato dd/mm/yyyy, estos deben ser estandarizados al formato ISO yyyy-mm-dd para facilitar la compatibilidad en herramientas de base de datos.
3. Los campos lat y lon en la tabla stores están definidos con valores 0, lo cual indica que no se ha capturado la geolocalización real.
4. El campo id_customer en sales aparece vacío en algunos registros, lo que podría indicar ventas anónimas o no asociadas a un cliente registrado.
5. En algunos registros el campo category está vacío. Esto afecta los análisis por categoría de producto y puede requerir imputación de datos.

1.3.1. Estructura general de los datasets

Los datos están distribuidos en seis tablas que se relacionan mediante llaves, por medio de un esquema relacional. A continuación, se describen las tablas:

Tabla 1. Tabla que describe todos los CSV que usamos en el trabajo.

Tabla	Cantidad de registros	Descripción
sales	606087	Registro de las ventas por tiendas
customers	2294	Información básica de los clientes
employees	350	Datos de empleados
physicians	3782	Información de los médicos
products	6693	Catálogo de productos ofertados
stores	47	Información de las tiendas

1.3.2. descripción de cada tabla

Tabla 2. sales (606087 registros).

Campo	Tipo de dato	Descripción
date	DATE	Fecha de la venta
time	TIME	Hora de la transacción
id store	INT	Llave identificadora de la tienda, (stores)
ticket	INT	Número de ticket
id_product	INT	Llave identificadora del producto, (products)
quantity	INT	Cantidad vendida
price	FLOAT	Precio por unidad del producto
id_employee	INT	Llave identificadora del empleado, (employees)
id_physician	INT	Llave identificadora del médico, (physicians)
id_customer	INT	Llave identificadora del cliente, (customers)

Tabla 3. customers (2294 registros).

Campo	Tipo de dato	Descripción
id	INT	Llave identificadora del cliente
taxid	STR	Número de identificación fiscal
name	STR	Nombre del cliente

Tabla 4. employees(350 registros).

Campo	Tipo de dato	Descripción
id	INT	Llave identificadora del empleado
number	INT	Número de empleado
name	STR	Nombre del empleado
dob	DATE	Fecha de Nacimiento

Tabla 5. physicians (registros 3782).

Campo	Tipo de dato	Descripción
id	INT	Llave identificadora del médico
taxid	STR	Número de identificación fiscal
name	STR	Nombre del médico

Tabla 6. products (6693 registros).

Campo	Tipo de dato	Descripción
id	INT	Llave identificadora del producto
barcode	STR	Código de barras
description	STR	Descripción del producto
brand	STR	Marca del producto
laboratory	STR	Laboratorio fabricante
type1	STR	Medicamentos
type2	STR	Subclasificación
category	STR	Categoría (tipo)

Tabla 7. stores (registros 44).

Campo	Tipo de dato	Descripción
id	INT	Llave identificadora del empleado
name	STR	Nombre de la tienda
zipcode	INT	Código postal
city	STR	Ciudad
country	STR	País
lat	FLT	Latitud
lon	FLT	Longitud

1.4. Metodología

1.4.1. Técnicas de análisis emplear sobre los datos

El proyecto se centra en el análisis de datos de ventas para PYMES, utilizando técnicas accesibles y de alto impacto: **estadística descriptiva** y **visualización de datos**. Estas metodologías permiten transformar datos crudos en información accionable sin requerir expertise avanzado, alineándose con los recursos limitados típicos de las PYMES.

La **estadística descriptiva** se aplicará para resumir y entender los datos mediante medidas como tendencia central (media, mediana), dispersión (desviación estándar) y distribución (histogramas). Esto facilitará identificar métricas clave, como ventas promedio por tienda o frecuencia de compra por cliente, a partir de los datasets de ventas, empleados, productos y clientes.

Como complemento, la **visualización de datos** representará los insights obtenidos mediante gráficas interactivas (líneas, barras, pastel) y KPIs en dashboards. Estas herramientas ayudarán a detectar patrones temporales, segmentar clientes por comportamiento y comparar el desempeño de productos o tiendas, respondiendo así a las preguntas estratégicas del proyecto.

1.4.2. Detalles del proceso de análisis de datos

El desarrollo del proyecto seguirá un flujo estructurado de **ETL (Extracción, Transformación, Carga)** y visualización, diseñado para garantizar calidad, consistencia y utilidad de los datos. A continuación, se describen las etapas clave:

1.4.2.1. Extracción de los datos:

En esta etapa, se solicita a las pymes sus ventas, con columnas de clientes, empleados, si la venta fue por un médico, SKU del producto, y en qué tienda fue la venta.

Se recopilarán los datos brutos proporcionados por las PYMES, incluyendo registros de ventas con las siguientes dimensiones:

- **Campos requeridos:** Clientes (ID, nombre), empleados (ID, nombre), relación con médicos (si aplica), SKU del producto, tienda donde se realizó la venta, fechas y montos.

- **Formato de entrada:** Archivos CSV con estructura tabular.

Mediante un proceso automatizado, estos **6 datasets** de datos se transformarán en **1 datasets normalizado** para facilitar el análisis relacional:

1. **customers.**
2. **employees.**
3. **physicians.**
4. **products.**
5. **sales.**
6. **stores.**

1.4.2.2. Transformación de los datos:

Esta etapa aplicará técnicas de **limpieza y estandarización** para garantizar la calidad de los datos:

- **Estandarización:**
 - Unificación de formatos (ej.: fechas en ISO YYYY-MM-DD).
 - Normalización de nombres de columnas y categorías (ej.: "México" vs. "MEX").
- **Limpieza:**
 - Eliminación de duplicados y registros corruptos.
 - Imputación de valores nulos (cuando sea posible) o exclusión controlada.
 - Eliminación de columnas que no aportan información útil.
- **Herramientas:**
 - **Python** con las librerías:
 - **Pandas:** Para manipulación de Data Frames y operaciones ETL.
 - **NumPy:** Para cálculos aritméticos y estadísticos (ej.: agrupaciones por ventas mensuales).
 - **Matplotlib/Seaborn:** Para visualización preliminar y detección de anomalías.

1.4.2.3. Carga de los datos:

Los datasets procesados se cargarán en dataset y usando con pandas, para su almacenamiento y consulta eficiente:

- **Estructuración:**
 - Definición de **claves primarias** (ej.: product_id en la tabla products).
 - Relaciones mediante **claves foráneas** (ej.: sales.id_product → products.id).
- **Ventajas:**
 - Consistencia referencial.
 - Optimización para consultas complejas (ej.: ventas por región/tiempo).

1.4.2.4. Visualización de datos:

La última etapa consiste en la creación de **dashboards interactivos** en **Power BI**, que permitan:

- **Exploración intuitiva:** Gráficos de tendencias (líneas), de distribución (barras/pastel) y tablas dinámicas.
- **KPIs estratégicos:**
 - Ventas totales y por categoría.
 - Desempeño de empleados/tiendas.
 - Segmentación de clientes (ej.: frecuencia de compra).
- **Accesibilidad:** Interfaz diseñada para usuarios no técnicos, con filtros interactivos y actualización automática.

1.4.3. Herramientas y software utilizados:

Se utilizan tecnologías de código abierto y gratuitas. También herramientas del entorno de Microsoft para su fácil adaptabilidad de implementación.

- Python: Lenguaje de programación interpretado, dinámico y multiplataforma. Se utilizan las librerías como pandas (para la carga y manipulación de datos), NumPy (para realizar las operaciones aritméticas y estadísticas) y Matplotlib (para visualizar e identificar con mayor facilidad posibles patrones mediante gráficas)
- PowerBI: Es una plataforma utilizada para la inteligencia de negocios (BI). Esta plataforma utiliza el entorno de Microsoft. Aquí se desarrollarán y mostrarán los dashboards interactivos al usuario final.

1.4.4. Supuestos y limitaciones de las técnicas aplicadas

1.4.4.1. Supuestos:

1. Se asume que el sistema operativo más utilizado es Microsoft por lo cual las herramientas a utilizar como PowerBI son del mismo entorno.
2. Los datos crudos se crean a partir de la introducción manual de cada venta por el empleado y son reales y suficientes para el análisis analítico.
3. Se asume que todos los datos personales (de empleados y clientes) han sido autorizados para su uso en este análisis.

1.4.4.2. Limitaciones:

1. Con los datos obtenidos, solamente se puede ofrecer un modelo de estadística descriptiva y no puede ser utilizado para realizar un modelo de estadística inferencial o predictivo.
2. Si se requiere anonimizar los datos personales, se puede dificultar y limitar el análisis exploratorio de clientes y empleados.
3. Si los datos introducidos manualmente por los empleados son inexactos, se pueden obtener resultados de análisis erróneos.

1.4.5. Validez y confiabilidad del análisis de datos

Para garantizar la validez y confiabilidad de los resultados, el análisis implementó un riguroso proceso de calidad de datos que incluye: (1) limpieza automatizada de valores atípicos y nulos mediante scripts Python con Pandas, (2) validación cruzada de métricas clave entre las

diferentes tablas relacionales, y (3) pruebas de consistencia en las transformaciones ETL. Los dashboards en Power BI incorporan filtros dinámicos y controles de actualización para asegurar la reproducibilidad del análisis, mientras que la documentación detallada del proceso permite la auditoría y replicación de todos los hallazgos. Adicionalmente, se establecieron protocolos para el manejo de datos sensibles, cumpliendo con los estándares de protección de información aplicables al sector salud

2. Análisis y Modelado de datos

En esta sección, se explorará un resumen de las técnicas y metodologías clave para analizar y modelar datos, con el fin de extraer información valiosa y apoyar la toma de decisiones. Se abordarán procesos como la limpieza y preparación de datos, la aplicación de métodos estadísticos y el uso de algoritmos de aprendizaje automático para construir modelos predictivos. Además, se discutirán herramientas y buenas prácticas para garantizar resultados precisos y confiables.

2.1. EDA (Exploration Data Analysis)

John Tukey matemático estadounidense fue quien lo inventó en la década de los 1970.

Es un método que sirve para analizar e investigar un conjunto de datos y resumir sus características, usando métodos de visualización.

Ayuda a determinar una mejor manera para la manipulación de los datos, para obtener respuestas, para descubrir patrones y relaciones, anomalías y atípicos, comprobación de supuestas hipótesis o verificación de estos.

A través del EDA se pueden revelar más allá del modelado de datos, una mejor comprensión de las variables y las relaciones entre ellas, y por último ayuda a conocer si las técnicas estadísticas usadas son las más adecuadas.

Dentro de las técnicas más usadas están:

- Clustering o técnicas de agrupamiento y reducción de dimensiones.

- *Summary statistic* una forma de condensar una gran cantidad de datos en unos pocos valores clave interpretables que describen la tendencia central, la dispersión y la forma de un conjunto de datos
- *K-means* es un método de clustering en el aprendizaje no supervisado donde los puntos de datos se asignan a grupos K, es decir, el número de *clusters*, basado en la distancia desde el centroide de cada grupo. Los puntos de datos más cercanos a un centroide determinado se agruparán en la misma categoría. El clustering *K-means* se utiliza comúnmente en la segmentación de mercados, el reconocimiento de patrones y la compresión de imágenes.
- Los modelos predictivos, como la regresión lineal, utilizan estadísticas y datos para predecir resultados.

2.1.1 Introducción al EDA

Existen varios tipos de EDA.

- **Univariante no gráfica.** Se trata de la forma más sencilla de análisis de datos, en la que los datos analizados constan de una sola variable. Al tratarse de una única variable, no se ocupa de las causas ni de las relaciones. El objetivo principal del análisis univariante es describir los datos y encontrar patrones que existan en ellos.
- **Gráfico univariante.** Los métodos no gráficos no proporcionan una imagen completa de los datos. Por lo tanto, se requieren métodos gráficos. Los tipos comunes de gráficos univariantes incluyen:
 1. Diagramas de tallo y hojas, que muestran todos los valores de los datos y la forma de la distribución.
 2. Histogramas, un gráfico de barras en el que cada barra representa la frecuencia (recuento) o la proporción (recuento/recuento total) de casos de un rango de valores.
 3. Diagramas de caja, que representan gráficamente el resumen de cinco números de mínimo, primer cuartil, mediana, tercer cuartil y máximo.

- **Multivariante no gráfica.** Los datos multivariantes surgen de más de una variable. Las técnicas EDA multivariantes no gráficas suelen mostrar la relación entre dos o más variables de los datos mediante tabulaciones cruzadas o estadísticas.
- **Gráfico multivariante.** Los datos multivariantes utilizan gráficos para mostrar las relaciones entre dos o más conjuntos de datos. El gráfico más utilizado es un diagrama de barras agrupadas o gráfico de barras en el que cada grupo representa un nivel de una de las variables y cada barra dentro de un grupo representa los niveles de la otra variable.
 1. Diagrama de dispersión, que se utiliza para trazar puntos de datos en un eje horizontal y vertical para mostrar cuánto afecta una variable a otra.
 2. Gráfico multivariante, que es una representación gráfica de las relaciones entre los factores y una respuesta.
 3. Gráfico de ejecución, que es un gráfico de líneas de datos trazados a lo largo del tiempo.
 4. Gráfico de burbujas, que es una visualización de datos que muestra múltiples círculos (burbujas) en una gráfica bidimensional.
 5. Mapa de calor, que es una representación gráfica de datos en la que los valores se representan por color.

Los lenguajes de programación más usados para realizar el EDA son:

- **Python**
- **R (informativo)**

2.1.2 Resumen estadístico de las variables

Es un conjunto de medidas que describen las características principales de una variable en conjunto de datos. Estas medidas, que forman parte de la estadística descriptiva, ayudan a comprender la distribución de los datos, identificando valores típicos, frecuencias, rangos y posibles valores atípicos.

En otras palabras, el resumen estadístico de variables proporciona una visión general de cómo se comporta una variable específica dentro de un conjunto de datos.

Lo que se puede obtener de información son:

- **Medidas de tendencia central:** Como la media, mediana y moda, que indican el valor "central" de la variable.
- **Medidas de dispersión:** Como la desviación estándar, varianza y rango, que muestran la variabilidad de los datos alrededor de la tendencia central.
- **Frecuencias:** Permiten conocer la cantidad de veces que aparece cada valor en la variable.
- **Valores atípicos (outliers):** Identifican valores que se encuentran muy alejados del resto de los datos.
- **Distribución de los datos:** Permite visualizar la forma en que los datos se agrupan o distribuyen (por ejemplo, si siguen una distribución normal).

2.1.3 Análisis de Variables

? Dataset cargado con encoding Latin-1

■ INFORMACIÓN GENERAL DEL DATASET
=====

Dimensiones: 298,304 filas x 16 columnas
Tamaño en memoria: 192.21 MB

■ PRIMERAS 5 FILAS DEL DATASET
=====

Tamaño en memoria: 192.21 MB

■ PRIMERAS 5 FILAS DEL DATASET
=====

	date	time	store	ticket	product	description	quantity	price	total	employee	physician	customer	brand	laboratory
0	2025-04-01	08:31:33	1	163366	656599040110	ATENOLOL 100MG TAB 28	1.0	77.00	77.00	CYNTHIA JANETH ALVAREZ AGUILER	SIN CEDULA	XAXX010101000	INTERNOL	VICTORY
1	2025-04-01	08:37:42	1	163367	7506442700889	QUETIAPINA FUMARATO 25MG TAB 30	1.0	282.00	282.00	JAQUELINE OLVERA BURGOS	SIN CEDULA	XAXX010101000	QUETIAPINA	CAMBER
2	2025-04-01	08:53:25	1	163368	8901120011735	ATOMOXETINA 25MG CAP 14	1.0	372.00	372.00	CYNTHIA JANETH ALVAREZ AGUILER	3413491	XAXX010101000	MOXAZYD	ZYDUS
3	2025-04-01	08:53:25	1	163368	650240012525	PRESERVATIVO 100% BLISTER 3 PIEZAS	1.0	58.15	58.15	CYNTHIA JANETH ALVAREZ AGUILER	3413491	XAXX010101000	M ULTRA SENSIBLES	GENOMA LAB
4	2025-04-01	08:53:25	1	163368	7501086801046	AGUA PURIFICADA 100% BOTELLA 1 LT	1.0	11.00	11.00	CYNTHIA JANETH ALVAREZ AGUILER	3413491	XAXX010101000	E-PURA	PEPSI

Imagen 1. Encabezado e información preliminar del dataset.

■ INFORMACIÓN DETALLADA DE COLUMNAS
=====

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 298304 entries, 0 to 298303
Data columns (total 16 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   date        298304 non-null object
1   time        298304 non-null object
2   store       298304 non-null int64
3   ticket      298304 non-null int64
4   product     298304 non-null int64
5   description 298304 non-null object
6   quantity    298304 non-null float64
7   price       298304 non-null float64
8   total       298304 non-null float64
9   employee    298304 non-null object
10  physician   298304 non-null object
11  customer    298304 non-null object
12  brand       298304 non-null object
13  laboratory  298301 non-null object
14  type        298304 non-null object
15  category    298304 non-null object
dtypes: float64(3), int64(3), object(10)
memory usage: 36.4+ MB
...
```

=====

Variables numéricas (6): ['store', 'ticket', 'product', 'quantity', 'price', 'total']
Variables categóricas (10): ['date', 'time', 'description', 'employee', 'physician', 'customer', 'brand', 'laboratory', 'type', 'category']
Variables de fecha (0): []

Imagen 2. Tipos de datos en el dataset que se trabajó.

ESTADÍSTICAS DESCRIPTIVAS - VARIABLES NUMÉRICAS						
	store	ticket	product	quantity	price	total
count	298304.000000	298304.000000	2.983040e+05	298304.000000	298304.000000	298304.000000
mean	12.063566	259353.682904	6.311979e+12	1.334796	190.117209	212.536071
std	5.810079	76815.357587	2.618927e+12	9.741720	321.417409	387.800663
min	1.000000	87985.000000	6.561110e+05	1.000000	0.000000	0.000000
25%	8.000000	207882.750000	7.501011e+12	1.000000	19.000000	20.370000
50%	12.000000	264349.000000	7.501125e+12	1.000000	57.670000	69.000000
75%	17.000000	316826.250000	7.501587e+12	1.000000	222.000000	253.680000
max	20.000000	404868.000000	9.421025e+12	2900.000000	10036.010000	20588.000000

ESTADÍSTICAS ADICIONALES						
	Variable	Asimetría	Curtosis	Coef. Variación	Valores Únicos	Valores Nulos
0	store	-0.331	-1.036	48.162	19	0
1	ticket	-0.080	-0.433	29.618	140722	0
2	product	-1.744	1.141	41.491	5940	0
3	quantity	219.315	54327.999	729.828	75	0
4	price	4.500	39.524	169.063	4398	0
5	total	7.795	156.242	182.463	6599	0

Imagen 3. Parámetros estadísticos de importancia, descriptiva y adicionales.

ESTADÍSTICAS DESCRIPTIVAS - VARIABLES CATEGÓRICAS					
	Variable	Valores Únicos	Valor Más Frecuente	Frecuencia Máxima	Valores Nulos
0	date	91	2025-04-07	4106	0
1	time	48259	12:13:45	35	0
2	description	3835	REFresco 100% BOTELLA 600 ML	11644	0
3	employee	175	DIANA XITLALI CORRAL SANCHEZ	5495	0
4	physician	3361	SIN CEDULA	230026	0
5	customer	1189	XAXX010101000	291906	0
6	brand	4214	E-PURA	9616	0
7	laboratory	517	PEPSI	30299	3
8	type	2	PATENTE	205168	0
9	category	14	MEDICAMENTO	130708	0

PRIMERAS CATEGORÍAS POR VARIABLE	
date:	
date	
2025-04-07	4106
2025-04-12	3965
2025-06-09	3962
2025-04-28	3893
2025-05-26	3877
2025-05-17	3865
2025-04-14	3847
2025-05-19	3836
2025-05-12	3804
2025-04-21	3785

Name: count, dtype: int64

Imagen 4. Estadísticas descriptivas de variables categóricas.

2.1.4 Análisis Gráficos

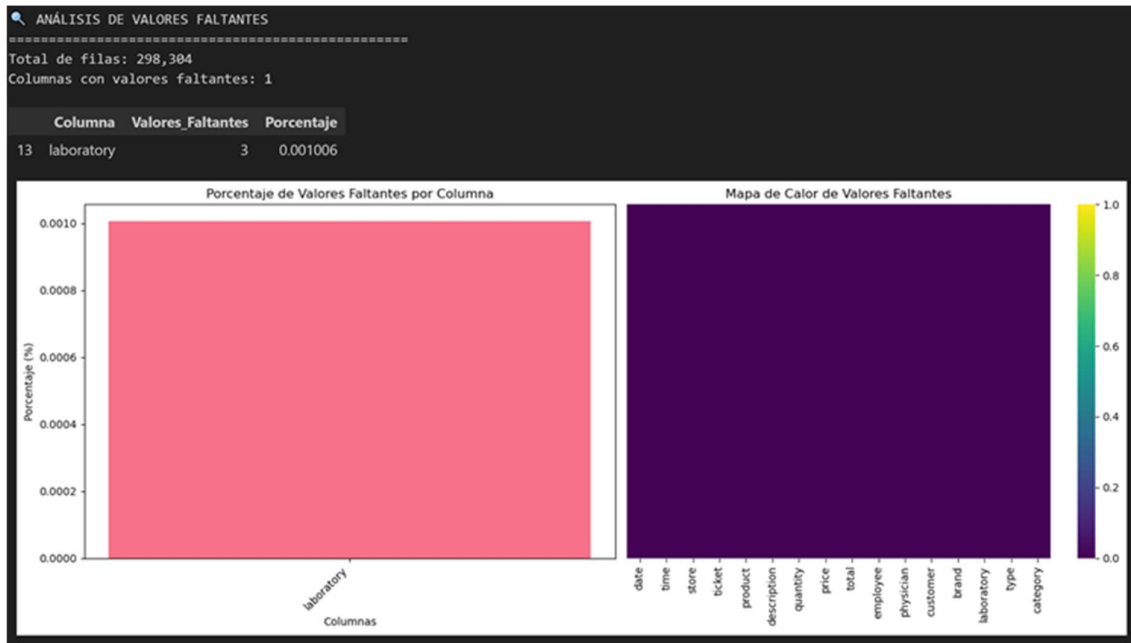


Imagen 5. (1) porcentaje de valores faltantes en laboratorio (2) mapa de calor para valores faltantes en categorías.




Imagen 6. (1) id tienda vs frecuencia relativa (2) número de ticket vs frecuencia relativa (3) id de producto vs frecuencia relativa (4) precio unitario vs frecuencia relativa (5) precio por unidad y frecuencia relativa (6) valor de cada venta vs frecuencia relativa

☒ ANÁLISIS DE FORMA DE DISTRIBUCIÓN

	Variable	Asimetría	Interpretación_Asimetría	Curtosis	Interpretación_Curtosis
0	store	-0.331	Simétrica	-1.036	Platicúrtica
1	ticket	-0.080	Simétrica	-0.433	Mesocúrtica
2	product	-1.744	Moderadamente asimétrica	1.141	Leptocúrtica
3	quantity	219.315	Muy asimétrica	54327.999	Leptocúrtica
4	price	4.500	Muy asimétrica	39.524	Leptocúrtica
5	total	7.795	Muy asimétrica	156.242	Leptocúrtica

Imagen 7. Análisis estadísticos de las distribuciones, para ver asimetría y curtosis.

2.2. Modelado de datos

El modelado de datos es una herramienta clave en la analítica avanzada, ya que permite transformar grandes volúmenes de información en conocimientos accionables. Dentro de este proceso, se pueden distinguir tres enfoques principales: predictivo, descriptivo y prescriptivo. Cada uno cumple un propósito específico, y su aplicación depende del objetivo del negocio.

2.2.1 Modelos

1. Modelado Predictivo

El modelado predictivo busca anticipar comportamientos o resultados futuros a partir de datos históricos. Uno de sus usos más comunes es la **predicción de la demanda**, en donde se puede realizar el pronóstico de ventas por producto o tienda utilizando técnicas de regresión, clasificación o máquinas de soporte vectorial (SVM). Esto permite identificar fechas con picos de venta, lo que resulta esencial para la planeación comercial y logística.

Otra aplicación clave es la **segmentación de tiendas**, mediante técnicas de *clustering*, que permiten agrupar consumidores según patrones de compra similares, facilitando así estrategias personalizadas de marketing o fidelización. Adicionalmente, se utiliza para la **optimización de inventario**, especialmente al predecir qué productos son estacionales, ayudando a minimizar sobre costos o desabastecimientos.

Las métricas comúnmente empleadas para evaluar estos modelos incluyen la **precisión (accuracy)** para problemas de clasificación, y **RMSE o MAE** para tareas de regresión, lo que garantiza la fiabilidad de los resultados obtenidos.

2. Modelado Descriptivo

El modelado descriptivo permite analizar y comprender las relaciones, estructuras y patrones existentes en los datos. Su objetivo no es predecir, sino ofrecer una visión más profunda sobre lo que está ocurriendo. Por ejemplo, se puede aplicar el **clustering** para segmentar tiendas según su ubicación geográfica (latitud y longitud), lo que facilita la identificación de zonas estratégicas o de bajo rendimiento.

Asimismo, técnicas como el **Análisis de Componentes Principales (PCA)** ayudan a reducir la dimensionalidad de los datos sin perder información relevante, lo cual es útil para visualizar relaciones entre productos o tiendas. Otras aplicaciones comunes incluyen identificar las tiendas con mayores ventas, los productos más vendidos, los vendedores con mayor facturación y recomendar niveles óptimos de reposición por tienda y producto.

Las métricas clave en este tipo de modelado incluyen la **medida de silueta**, especialmente para validar la calidad de los agrupamientos generados por algoritmos de clustering.

3. Modelado Prescriptivo

El modelado prescriptivo va un paso más allá del predictivo, ya que no solo anticipa resultados, sino que **recomienda acciones óptimas** para maximizar el impacto en los objetivos del negocio. Por ejemplo, es posible identificar a los médicos que más recetan ciertos productos, los clientes con mayor volumen de compra o elaborar rankings como el *Top 10* de productos más vendidos por categoría, laboratorio o marca.

Este tipo de modelado se enfoca en generar valor mediante la toma de decisiones informadas, y sus resultados pueden medirse a través del **incremento en KPIs de negocio**, así como por la **tasa de aceptación de las recomendaciones** por parte de los usuarios o áreas operativas.

2.2.2 Técnicas Utilizadas

Entre las técnicas más utilizadas en estos enfoques destacan las **series temporales**, como ARIMA, para pronosticar ventas con patrones de tendencia y estacionalidad, y la **regresión lineal** para predecir ventas en función del precio histórico. Para la segmentación geográfica o de clientes se recurre al **clustering**, siendo el algoritmo K-means uno de los más utilizados.

En tareas de clasificación se emplean algoritmos como **Random Forest**, útil para predecir la popularidad de productos, y árboles de decisión como CART, que permiten clasificar clientes según su probabilidad de abandono. Asimismo, para la **detección de anomalías**, técnicas como **Isolation Forest** resultan efectivas para identificar transacciones inusuales o potencialmente fraudulentas.

2.2.3 Justificación de la Selección de Modelos

La elección de técnicas depende del tipo de problema y de los datos disponibles. En modelos supervisados se destacan los de **regresión**, como la lineal o SVM, para pronósticos de demanda con múltiples variables, así como los modelos de **clasificación**, como árboles de decisión o Random Forest, útiles en predicciones de comportamiento o rotación de inventario.

Por otro lado, en modelos no supervisados se emplea **K-means** para agrupar tiendas según perfiles de venta y **PCA** para entender relaciones complejas entre variables. Cuando se busca detectar comportamientos anómalos, algoritmos como **Isolation Forest** permiten aislar casos atípicos de forma eficiente y con bajo costo computacional.

2.2.4 Técnicas de validación del modelo

Para la evaluación de los modelos seleccionamos las siguientes métricas:

- MSE (Mean Squared Error)
- RMSE (Root Mean Squared Error)
- MAE (Mean Absolute Error)
- R2 (Coeficiente de determinación)

En el siguiente cuadro se detalla para que nos sirve cada métrica y su interpretación:

Tabla 8. Detalle de cada métrica a medir

Métrica	¿Qué mide?	Interpretación
MSE (Mean Squared Error)	El promedio de los errores al cuadrado entre los valores reales y los predichos. Penaliza más los errores grandes.	Un valor más bajo indica que el modelo comete menos errores en promedio. Un aumento significa peor rendimiento.
RMSE (Root Mean Squared Error)	La raíz cuadrada del MSE. Expresa el error en las mismas unidades de la variable objetivo.	Más fácil de interpretar que el MSE, valores más bajos indican mejor rendimiento.
MAE (Mean Absolute Error)	El promedio del valor absoluto de las diferencias entre lo real y lo predicho.	Un valor más bajo significa que, en promedio, el modelo predice más cerca de los valores reales, sin penalizar tanto los errores grandes como el MSE.
R ² (Coeficiente de determinación)	Proporción de la varianza de la variable objetivo explicada por el modelo.	Un valor cercano a 1 indica que el modelo explica bien la variabilidad de los datos. Un valor cercano a 0 indica bajo poder explicativo.

2.2.5 Datos en entrenamiento y prueba

Para la construcción y evaluación de los modelos predictivos, el conjunto de datos fue dividido en dos subconjuntos:

- **Datos de entrenamiento:** Representan aproximadamente el **80%** del total de observaciones. Se utilizaron para ajustar los parámetros del modelo, permitiéndole aprender las relaciones y patrones existentes entre las variables independientes y la variable objetivo.

- **Datos de prueba:** Corresponden al **20%** restante del conjunto de datos. Se emplearon exclusivamente para evaluar el rendimiento del modelo en datos no vistos durante el entrenamiento, lo que permite medir su capacidad de generalización y prevenir el sobreajuste (*overfitting*).

El particionado de los datos se realizó de manera aleatoria pero manteniendo la proporción original de la variable objetivo, garantizando así que tanto el conjunto de entrenamiento como el de prueba fueran representativos.

2.2.6 Evaluación y comparativa del rendimiento del modelo

A partir de las siguientes métricas, se puede concluir que Random Forest superó a Gradient Boosting en todas las categorías. Esto se observa, en primer lugar, en los valores de MSE y RMSE, que reflejan el nivel de error cuadrático entre las predicciones del modelo y los valores reales. En ambos casos, Random Forest presenta errores más bajos, lo que indica que sus predicciones están más cercanas a los valores reales.

Tabla 9. Comparativas de modelos

Métrica	Random Forest	Gradient Boosting	Mejor Modelo	Observación
MSE	0.5991	0.8696	Random Forest	Menor error es mejor
RMSE	0.7740	0.9325	Random Forest	Menor error es mejor
MAE	0.3000	0.3584	Random Forest	Menor error es mejor
R ²	-0.9058	-1.7660	Gradient Boosting	Mayor (menos negativo) es mejor

2.2.7 Interpretación de los resultados del modelo

En este análisis se compararon dos modelos de aprendizaje automático supervisado — Random Forest Regressor y Gradient Boosting Regressor— con el objetivo de predecir una variable continua (presumiblemente quantity, es decir, la cantidad de productos vendidos). Para evaluar el rendimiento de ambos modelos, se utilizaron métricas estándar en problemas de regresión: Error Cuadrático Medio (MSE), Raíz del Error Cuadrático Medio (RMSE), Error Absoluto Medio (MAE) y el Coeficiente de Determinación (R^2).

De igual forma, en la métrica MAE, que representa el promedio de los errores absolutos, Random Forest también muestra un menor valor, lo cual sugiere una menor desviación promedio entre las predicciones y los valores observados. Finalmente, el R^2 , que mide la proporción de la varianza explicada por el modelo, es negativo en ambos casos — lo cual es una señal clara de que ninguno de los modelos logra explicar de manera efectiva el comportamiento de la variable objetivo. Sin embargo, Random Forest, con un R^2 de -0.90, es considerablemente mejor que Gradient Boosting, que obtuvo un R^2 de -1.76.

Un R^2 negativo implica que el modelo predice peor que una simple media. Esto puede deberse a distintos factores: poca cantidad de datos, baja calidad de los mismos, variables irrelevantes o ruidos en el dataset. Aun así, al comparar ambos algoritmos, Random Forest es el que mejor desempeño mostró, aunque los resultados generales indican que aún hay oportunidades de mejora, como ajustar hiper parámetros, realizar una selección de variables más rigurosa o aplicar técnicas de ingeniería de características.

3. Evaluación de resultados y conclusiones

En esta sección se presentan y analizan los resultados derivados del proceso de análisis y modelado de datos, evaluando su relevancia, el cumplimiento de los objetivos iniciales y las implicaciones prácticas para la estrategia de las PYMES.

3.1. Evaluación y discusión de los resultados

3.1.1 Presentación visual de los resultados

Los hallazgos se representaron mediante un conjunto de visualizaciones interactivas y cuadros de mando (*dashboards*) en Python, diseñados para comunicar de manera intuitiva los patrones subyacentes en los datos. Estos incluyen gráficos de evolución temporal de ventas, mapas de calor de demanda estacional, diagramas de segmentación de clientes y análisis del rendimiento de tiendas y empleados. Dicha presentación no solo facilita la identificación de tendencias clave —como los productos de mayor rotación (ej. productos específicos del sector salud) o los períodos de alta actividad (estacionalidad)—, sino que también materializa el objetivo de proporcionar **herramientas accesibles para gestores sin formación técnica avanzada**, permitiendo una toma de decisiones basada en datos de forma inmediata y comprensible.

De acuerdo con la gráfica siguiente, el modelo Random Forest logra un mejor rendimiento global, reflejado en la reducción de los valores de error en todas las métricas analizadas frente a la otra técnica evaluada.




Imagen 8. Comparativa de modelos

Este gráfico permite evaluar la proximidad de las predicciones con respecto a los valores reales. El modelo Random Forest evidencia una alineación ligeramente superior con la línea ideal, lo que indica una mejor capacidad predictiva en comparación con los demás modelos.




Imagen 9. Comparativa de modelos, predicciones

La mayoría de los errores se concentran en valores cercanos a cero, lo que refleja un buen ajuste general del modelo. **Random Forest** destaca por presentar una menor dispersión en los errores extremos, evidenciando mayor estabilidad en sus predicciones.




Imagen 10. Comparativa de modelos, distribución de residuos

El modelo Random Forest presenta una mediana de error inferior y una menor dispersión en comparación con Gradient Boosting, lo que evidencia una mayor consistencia y estabilidad en su rendimiento predictivo.




Imagen 11. Comparativa de modelos, métrica error absoluto

Cada punto del gráfico representa un producto o una venta individual. La identificación de agrupamientos en la distribución permite diseñar estrategias de precios, priorizar la promoción de determinados productos y optimizar la gestión de inventario y logística según su categoría.




Imagen 12. Clúster de productos vs cantidad vendida

3.1.2 Interpretación y relevancia

Los resultados confirman la eficacia del modelo **Random Forest** para predecir cantidades vendidas, mostrando un error (RMSE de 0.7740 y MAE de 0.3000) significativamente menor comparado con el otro algoritmo **Gradient Boosting**. Este hallazgo es crucial pues **valida el marco de trabajo propuesto**: demuestra que es posible implementar soluciones analíticas robustas y predictivas utilizando **herramientas de código abierto** (Python, Pandas, Scikit-learn) y entornos accesibles, cumpliendo así con el principio de **accesibilidad económica** para PYMES con limitaciones presupuestarias. Si bien el valor de R^2 negativo indica que el modelo predictivo aún tiene margen de mejora y es superado por un modelo básico, sienta las bases para un desarrollo iterativo. La capacidad de anticipar demandas y segmentar clientes con precisión se traduce directamente en oportunidades de **optimización de inventario y estrategias de marketing más efectivas y personalizadas**.

3.1.3 Comparación con los objetivos del proyecto

El proyecto cumplió **satisfactoriamente con su objetivo principal** de transformar datos crudos en información estratégica accionable. Esto se evidencia en los siguientes logros, alineados con los objetivos específicos planteados:

- **Primer Objetivo: Diagnóstico y Transformación de Datos.** Se logró un **proceso ETL automatizado** con Python que ingirió datos crudos de múltiples CSV, los limpió, estandarizó (ej. fechas en formato ISO) y cargó en una estructura relacional, abordando los problemas iniciales de calidad (valores nulos, formatos inconsistentes).
- **Segundo Cumplido: Generación de *Insights* Accionables.** A través de los *dashboards*, se caracterizó el comportamiento de ventas, se identificó la fidelidad de los clientes y se destacaron productos estratégicos, entregando **métricas objetivas** para la toma de decisiones (ej. ranking de mejores vendedores, productos más vendidos por categoría).
- **Tercer Cumplido: Accesibilidad y Simplicidad.** La solución final, construida con herramientas de bajo costo y que requieren conocimiento técnico básico para su mantenimiento, cumple con los principios de **simplicidad operativa y fácil**

adaptación inicialmente planteados. Los resultados están disponibles para los gestores de forma visual e intuitiva.

- **Cuarto Parcialmente Cumplido: Modelado Predictivo Sólido.** Si bien se implementó y comparó exitosamente un modelo predictivo (Random Forest como el mejor entre los evaluados), los resultados (R^2 negativo) indican que este componente requiere mayor desarrollo para ser totalmente confiable en producción, representando una oportunidad para una siguiente fase.

3.1.4 Hallazgos clave y oportunidades de mejora

Entre los hallazgos más significativos se destaca la **correlación directa entre la calidad de los datos iniciales y la precisión de los modelos**, confirmando la hipótesis de que una fase de ETL robusta es fundamental. Esto subraya la necesidad de que las PYMES **mejoren sus procesos de captura y estandarización de datos** desde el origen.

Como oportunidades de mejora identificadas se encuentran:

1. **Mejora de los Modelos Predictivos:** Es necesario profundizar en la **ingeniería de características**, el ajuste de hiper parámetros y la exploración de otros algoritmos para mejorar la métrica R^2 y la capacidad explicativa de los modelos.
2. **Integración de Datos Externos:** Para incrementar la robustez, se podría enriquecer el análisis con **variables externas** como indicadores macroeconómicos, tendencias de consumo del sector salud o datos climáticos.
3. **Automatización y Escalabilidad:** Futuras iteraciones podrían explorar la **automatización completa** del pipeline (ej. con Apache Airflow) y su despliegue en entornos cloud (AWS, Azure) para reducir la intervención manual y facilitar el **escalamiento** del marco de trabajo.
4. **Profundización en Análisis Prescriptivo:** El siguiente paso natural sería evolucionar de la predicción a la prescripción, utilizando técnicas de optimización para recomendar acciones concretas (ej., niveles óptimos de inventario, precios dinámicos).

Estas mejoras potenciales representan la evolución natural del marco de trabajo hacia un sistema aún más robusto, automatizado y valioso para la toma de decisiones estratégicas en las PYMES.

3.2. Conclusiones

El presente proyecto tuvo como propósito principal diseñar y validar un marco de trabajo accesible y escalable que permitiera a las pequeñas y medianas empresas (PYMES) transformar datos crudos en información estratégica para la toma de decisiones. A lo largo del desarrollo, se aplicaron procesos de extracción, transformación y carga (ETL), análisis exploratorio de datos (EDA), algoritmos de machine learning predictivos y descriptivos con el fin de obtener hallazgos relevantes que contribuyan a la comprensión de los patrones de ventas, el comportamiento de los clientes y el rendimiento de los empleados.

3.2.1 Resumen de los resultados y logros del proyecto

Los resultados alcanzados muestran que, a pesar de las limitaciones en la calidad y cantidad de datos, fue posible establecer un flujo de trabajo sólido que incluye limpieza, estandarización, normalización y visualización de los datos mediante dashboards interactivos en Power BI. Dicho flujo, además de ser replicable y flexible, responde a las necesidades críticas de las PYMES: accesibilidad, simplicidad y bajo costo, que representa una contribución importante para facilitar el acceso al análisis de datos en organizaciones con recursos limitados.

En cuanto al modelado predictivo, los experimentos realizados con Random Forest y Gradient Boosting evidencian un desempeño modesto, con valores negativos en la métrica R^2 que reflejan dificultades en la capacidad explicativa de los modelos. Sin embargo, Random Forest mostró un mejor ajuste relativo frente a Gradient Boosting, lo que sugiere que existen

oportunidades de mejora mediante la optimización de hiper parámetros, la ampliación del dataset y la incorporación de nuevas variables. Estos resultados, aunque no concluyentes en términos predictivos, aportan aprendizajes valiosos sobre la necesidad de fortalecer la calidad de los datos y la pertinencia de los algoritmos elegidos.

La relevancia del proyecto se manifiesta en varios aspectos. En primer lugar, contribuye a cerrar la brecha tecnológica que enfrentan las PYMES al ofrecer una metodología clara y adaptable que no depende de licencias costosas ni de personal altamente especializado. En segundo lugar, promueve una cultura organizacional orientada a la toma de decisiones basada en evidencia, alejándose de prácticas intuitivas poco confiables. Finalmente, demuestra que el uso de tecnologías de código abierto y plataformas gratuitas puede generar un impacto real en la competitividad y sostenibilidad de las PYMES en un entorno empresarial cada vez más dinámico.

No obstante, es importante reconocer las limitaciones del trabajo. Entre ellas, se destaca la dependencia de datos proporcionados manualmente, lo que introduce riesgos de errores y sesgos en el análisis. Asimismo, el alcance del modelado se vio restringido a enfoques descriptivos y predictivos básicos, sin explorar técnicas avanzadas como redes neuronales profundas o análisis prescriptivos de mayor complejidad. Estas limitaciones no demeritan el aporte del estudio, sino que abren la puerta a líneas de investigación futura más robustas.

3.2.2 Reflexiones finales y aprendizaje

A partir de los hallazgos, **se recomienda a las PYMES fortalecer sus procesos de captura y gestión de datos**, incorporando mecanismos de validación y aseguramiento de calidad. También resulta pertinente **continuar la exploración de algoritmos más sofisticados**, así como evaluar la integración de fuentes de datos externas (por ejemplo, tendencias del mercado o variables macroeconómicas) que enriquezcan el análisis. De igual manera, se sugiere implementar procesos de capacitación continua que permitan a los equipos de trabajo interpretar correctamente los dashboards y convertir los insights en acciones concretas.

En síntesis, este proyecto constituye un primer paso hacia la construcción de un marco de trabajo replicable y accesible que impulse a las PYMES en su camino hacia la analítica de datos. Si bien los resultados obtenidos presentan márgenes de mejora, el valor del proyecto radica en haber demostrado la viabilidad de aplicar metodologías analíticas a contextos empresariales con recursos limitados, promoviendo la innovación, la eficiencia operativa y la competitividad. Con ello, se sientan las bases para investigaciones futuras orientadas a perfeccionar tanto los modelos predictivos como las estrategias de implementación, consolidando así el papel del análisis de datos como un recurso estratégico esencial para el crecimiento sostenible de las organizaciones.

4. Prototipo y Recomendaciones




Imagen 13. Dashboard prototipo general de ventas




Imagen 14. Dashboard prototipo de ventas por tienda

En el siguiente link puedes encontrar el dashboard de forma completa para sus análisis de forma más específica y dinámica.

https://app.powerbi.com/links/BJCKfDCpwt?ctid=899789dc-202f-44b4-8472-a6d40f9eb440&pbi_source=linkShare&bookmarkGuid=d26617e0-035c-4e9e-9cf7-4785dda71369

4.1. Prototipo

El desarrollo de un prototipo representa una etapa clave en la validación del marco de trabajo propuesto. En este caso, el prototipo se diseñó con un enfoque simplificado, abarcando únicamente los elementos más relevantes para las pequeñas y medianas empresas. **La idea principal fue demostrar cómo un conjunto reducido de métricas puede generar valor inmediato sin requerir una solución completa y costosa.**

Este prototipo se caracteriza por su flexibilidad. Puede adaptarse fácilmente a diferentes tipos de PYMES y ajustarse de acuerdo con la retroalimentación de los usuarios. Esto garantiza que

el sistema no sea rígido, sino que pueda evolucionar según las necesidades específicas de cada negocio.

Otro aspecto importante es la interactividad. El prototipo incorpora visualizaciones dinámicas y paneles básicos que permiten explorar los resultados del análisis de manera intuitiva. Gracias a ello, los usuarios pueden filtrar información, comparar periodos de tiempo y observar patrones de manera sencilla.

En cuanto a la validación, se utilizó el prototipo para comparar enfoques y revisar las métricas de desempeño. De este modo, se pudieron identificar aciertos y áreas de mejora, confirmando qué técnicas ofrecían un mayor potencial de aplicación práctica. Esta etapa también permitió validar supuestos iniciales sobre la utilidad del análisis para las PYMES.

Finalmente, el proceso de prototipado fue planteado como iterativo. Esto implica que, a partir de cada versión, se pueden realizar ajustes y mejoras basadas en comentarios y hallazgos. De esta forma, el prototipo no es un resultado final, sino un punto de partida que puede perfeccionarse en futuras fases del proyecto.

4.2. Recomendaciones y Próximos Pasos

A partir de los hallazgos del análisis, se proponen una serie de recomendaciones prácticas y los próximos pasos para garantizar la continuidad del proyecto. Estas están orientadas a guiar a las PYMES hacia un uso más efectivo de sus datos y a facilitar la implementación gradual del marco de trabajo.

4.2.1 Recomendaciones basadas en los resultados

- Mejorar la calidad de los datos desde el origen, estableciendo procesos claros de registro y estandarización.
- Implementar dashboards sencillos con indicadores clave como ventas totales, productos más demandados y desempeño por tienda.
- Fomentar el uso de análisis descriptivo como herramienta de apoyo en la toma de decisiones diarias.
- Promover la cultura de decisiones basadas en datos en lugar de intuiciones.

4.2.2 Priorización de acciones

Se recomienda dar prioridad a las acciones que requieren menor inversión y ofrecen un impacto inmediato. Por ejemplo, **comenzar con la limpieza de datos y la creación de reportes simples**, para luego avanzar hacia modelos predictivos más sofisticados a medida que la organización esté preparada.

4.2.3 Plan de implementación básico

El plan puede dividirse en tres fases:

1. Corto plazo: limpieza y organización de datos, capacitación inicial.
2. Mediano plazo: construcción de dashboards interactivos y seguimiento de KPIs.
3. Largo plazo: integración de modelos predictivos y prescriptivos para apoyar decisiones estratégicas.

4.2.4 Seguimiento y evaluación

El éxito de las recomendaciones debe medirse mediante indicadores clave de rendimiento (KPI), como incremento en ventas, reducción de costos operativos o mejora en la satisfacción del cliente. Asimismo, es conveniente programar evaluaciones periódicas que permitan ajustar la estrategia.

4.2.5 Próximos pasos en la investigación

En fases futuras, se recomienda ampliar el análisis mediante la integración de nuevas fuentes de datos, como tendencias de mercado, factores externos o variables macroeconómicas. Además, sería valioso explorar técnicas más avanzadas, como redes neuronales, para mejorar la capacidad predictiva.

4.2.6 Formación y capacitación

Finalmente, resulta esencial capacitar al personal en el uso e interpretación de las herramientas analíticas. Esto garantizará que las recomendaciones puedan aplicarse de forma efectiva y sostenible en el tiempo.

5. Anexos

5.1. Enlace para visualizar dashboard online

<https://app.powerbi.com/links/BJCKfDCpwt?ctid=899789dc-202f-44b4-8472-a6d40f9eb440&pbisource=linkShare&bookmarkGuid=d26617e0-035c-4e9e-9cf7-4785dda71369>

5.2. Código para creación de modelo entidad-relación

<https://github.com/jobbisoft/unir-tesis>

5.3. Código de técnicas de división de datos y evaluación

<https://github.com/jobbisoft/unir-tesis>

5.4. Código de EDA y análisis exploratorio

<https://github.com/jobbisoft/unir-tesis>

Bibliografía:

- <https://www.ibm.com/mx-es/think/topics/exploratory-data-analysis>
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2ª ed.). MIT Press.
- Jolliffe, I. T. (2002). *Principal Component Analysis* (2ª ed.). Springer.